4. Parallelprogrammierung

AlDaBi Praktikum

Inhalt

- Einführung in Parallelität
- OpenMP

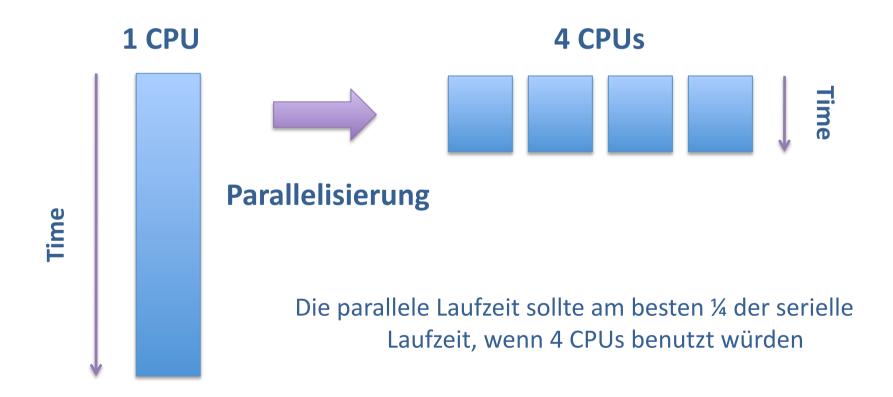
Bemerkungen zur P-Aufgabe

EINFÜHRUNG IN PARALLELITÄT

Folien z.T. aus VL "Programmierung von Hardwarebeschleunigern" von Alexander Reinefeld und Thomas Steinke, WS09

Was ist Parallelität?

- Parallelität ist eine Optimierungstechnik um die Laufzeit zu reduzieren
- Dazu wurden benutzt mehrere Prozessoren (CPUs oder Cores)



Parallele Plattformen

Gemeinsamer Speicher Verteilter Speicher (shared memory) (distributed memory) CPU CPU CPU CPU CPU CPU Cache Cache Cache Cache Cache Cache Gemeinsamer Bus RAM **RAM RAM** 1/0 RAM Netzwerk

Prozesskommunikation ...

Gemeinsamer Speicher

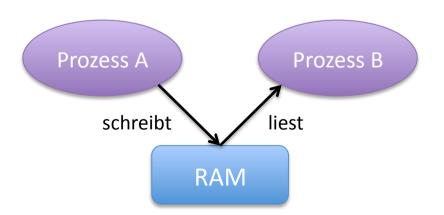
(shared memory)

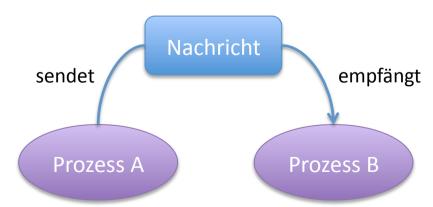
- ... über gemeinsameSpeicherbereich
 - Schreiben/Lesen im RAM
 - Synchronisation über gegenseitigen Ausschluss

Verteilter Speicher

(distributed memory)

- ... über Nachrichtenaustausch (message passing)
 - Senden/Empfangen von Nachrichten
 - Nur lokale (private) Variablen





Process VS Thread

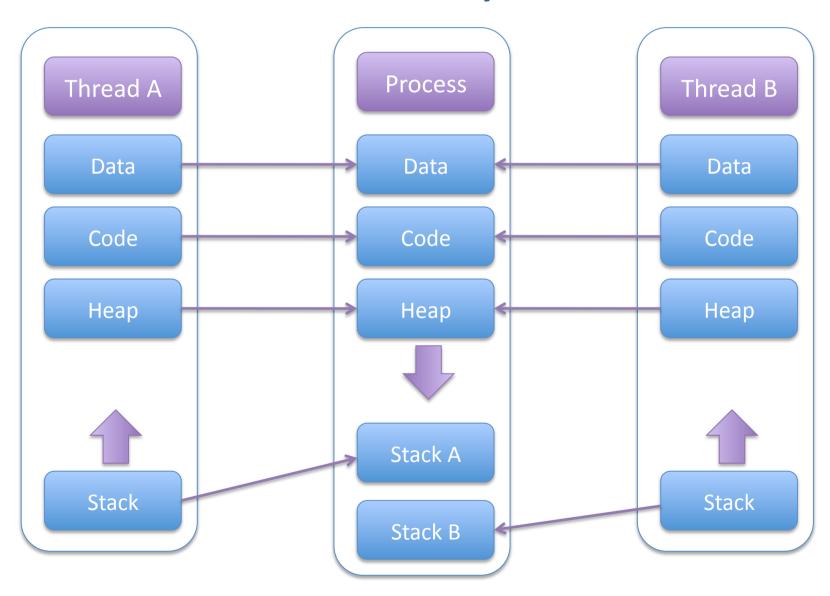
Prozess

- Laufende Instanz eines Programms
- Besteht aus eigenem Adressraum
 - Für Stack, Heap, Programmcode, ...
 - Ist dadurch vor anderen Prozessen geschützt
- Kann Resourcen reservieren
- Hat einen oder mehrere Threads, die den Code ausführen

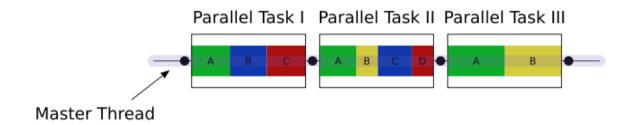
Thread

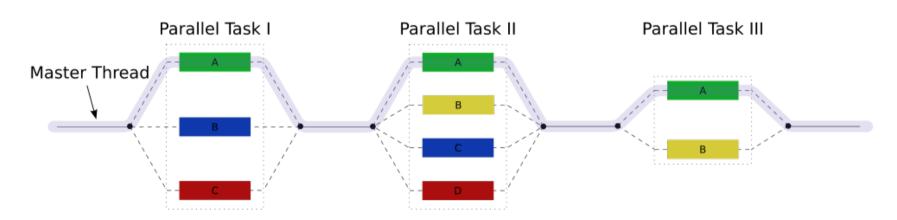
- Ausführungseinheit des Prozess
- Bestehen aus eigenem Stack und CPU-Registerzustand
- Haben den Adressraum des zugehörigen Prozesses
 - Threads desselben Prozesses sind nicht voreinander geschützt
- Beispiel: Auf mehrere Threads verteilte for-Schleife eines Programms

Prozesslayout



Fork & Join Modell

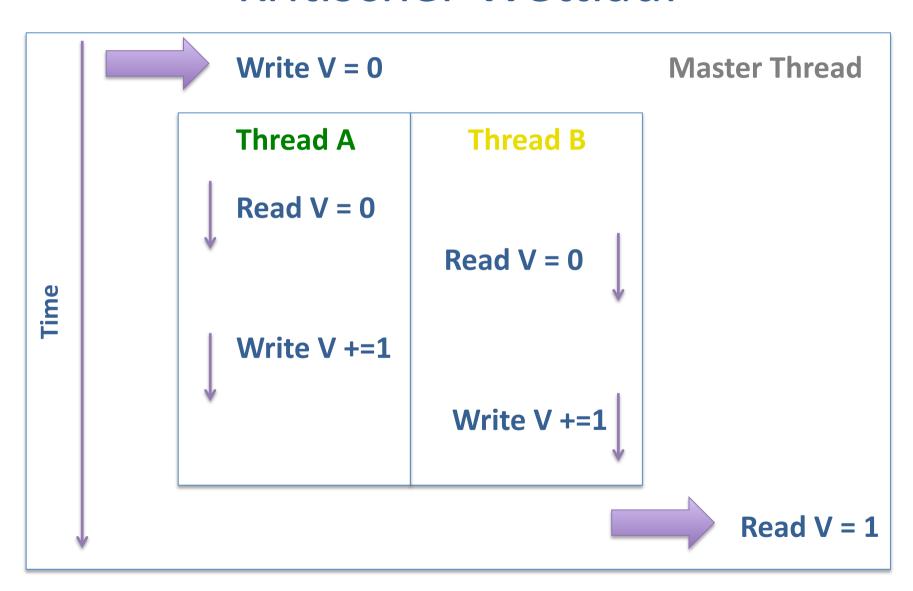




Fallstricke

- Kritischer Wettlauf (Race Condition)
 - Situationen, in denen das "Wettrennen" (race) der Prozesse beim Zugriff auf gemeinsame Ressourcen Auswirkungen auf das Ergebnis eines Programmlaufs hat
 - Beispiel: 2 Threads schreiben in dieselbe Speicherstelle
- Verklemmung (Deadlock)
 - Threads warten gegenseitig auf die Resourcen der anderen
- Aushungern (Starvation)
 - Ressource wechselt unfairerweise nur innerhalb einer Gruppe von Threads
 - Threads außerhalb der Gruppe erhalten die Resource nie

Kritischer Wettlauf



Lösung

Synchronisation

- Mutex (Mutual Exclusion)
 - Kann von mehreren Threads verlangt werden (lock), aber nur einer besitzt sie bis er sie freigibt (unlock)

Semaphore

- Kann von mehreren Threads verlangt werden, ist aber immer nur in Besitz von höchstens k Threads
- Mutex ist Semaphore mit k=1

Barrier

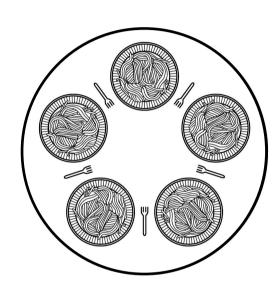
• Eine Gruppe von Threads hält solange an einer Barriere an, bis alle angekommen sind, danach laufen alle weiter

Verklemmung

- Philosophenproblem Algorithmus:
 - Denk bis die linke Gabel ist verfügbar
 - Denk bis die rechte Gabel ist verfügbar
 - Iss
 - Lieg die rechte Gabel ab
 - Lieg die linke Gabel ab
 - Wiederhole

Verklemmung

- Jeder nimmt die linke Gabel auf und wartet auf die rechte
- Lösung
 - Eine Mutex für den ganzen Tisch zum Prüfen und Aufnehmen zweier Gabeln
 - Semaphore mit k=4



OPEN MULTI-PROCESSING

Einführung

- OpenMP stellt eine Programmierschnittstelle (API) f
 ür C/C++ (und Fortran) zur Verf
 ügung
 - Erweiterung der Programmiersprache durch #pragma-Direktiven
 - Eine Direktive besteht aus einem Namen und einer Klauselliste: #pragma omp directive [clause list]
 - Bibliotheksfunktionen
 - #include <omp.h>
- Nur für Plattformen mit gemeinsamen Speicher (shared memory)

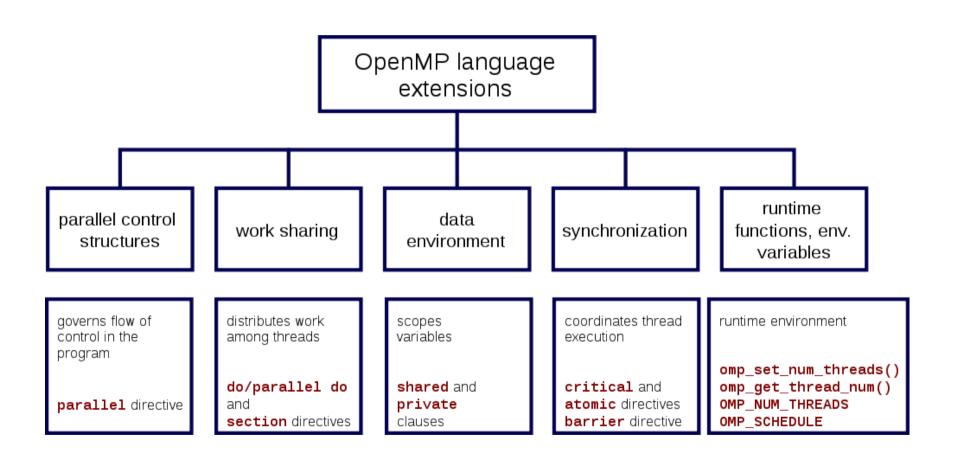
- Nützliche Links
 - OpenMP Homepage http://www.openmp.org/
 - OpenMP Tutorial http://computing.llnl.gov/tutorials/openMP/
 - Kurzübersicht http://www.openmp.org/mp-documents/OpenMP3.0-SummarySpec.pdf

Verfügbarkeit

Compiler	OpenMP Unterstützung	Compiler Schalter
g++	GCC 4.2: OpenMP 2.5 GCC 4.4: OpenMP 3.0	-fopenmp
Visual C++	VS 2005-2010: OpenMP 2.0	/openmp In der IDE*
Intel C++	V9: OpenMP 2.5 V11: OpenMP 3.0	Windows: /Qopenmp Linux: -openmp
Sun Studio	V12: OpenMP 2.5 V12 U1: OpenMP 3.0	-xopenmp

- OpenMP aktivieren in Visual Studio 2005 oder später:
 - Öffne Properties des Projektes und gehe zu:
 Configuration Properties -> C/C++ -> Language
 - Setze OpenMP Support auf yes
- Achtung:
 - Visual Studio 2005 Express Edition unterstüzt kein OpenMP, obwohl der Schalter existiert

Überblick



OpenMP Beispiel

• Einfaches Beispielprogramm in OpenMP:

```
#include <cstdio>
#include <omp.h>

int main(int, char*[])
{
    #pragma omp parallel
    printf("Hello, world.\n");

    return 0;
}
```

Ausgabe auf Intel Core 2 Duo:

```
Hello, world.
Hello, world.
```

OpenMP Beispiel (II)

• **Unterscheidung** der Threads:

```
#include <cstdio>
#include <omp.h>

int main(int, char*[])
{
    #pragma omp parallel
    printf("I'm thread %i of %i.\n",
        omp_get_thread_num(),
        omp_get_num_threads());

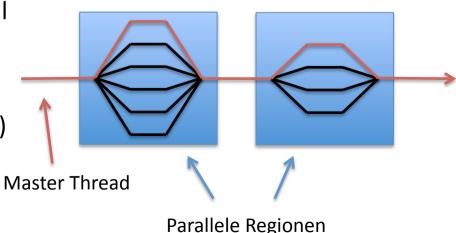
return 0;
}
```

Ausgabe:

```
I'm thread 0 of 2.
I'm thread 1 of 2.
```

Programmiermodell

- Parallelität lässt sich schrittweise erzeugen
 - Ein serielles Programm wird zu einem parallelen
 - Serielle Version weiterhin nutzbar
- Direktive parallel startet ein Team
 - Aktueller Thread ist Master
 - Alle Threads bearbeiten den folgenden Abschnitt
- Direktive for teilt Iterationen auf Team-Mitglieder auf
 - Jeder Thread bearbeitet einen Teil
- Ende des parallelen Blocks
 - Implizite Synchronisation (barrier)
 - Nur Master läuft weiter



Von seriell zu parallel

Serielles Programm:

```
double A[10000];
for (int i = 0; i < 10000; ++i)
   A[i] = langwierige_berechnung(i);</pre>
```

- Die berechnungen sind unabhängig
 - langwierige_berechnung braucht nur i
- Die Schleife ist sehr einfach parallelisierbar

parallel

- Parallele Ausführung mit parallel
 - Folgender Block wird von allen Threads parallel ausgeführt
 - Programmierer verteilt die Arbeit
 - Entweder manuell
 - Oder mit weiteren Direktiven, bspw. for, sections, ...

```
double A[10000];
int cnt = omp_get_num_threads();
#pragma omp parallel
{
   int id = omp_get_thread_num();
   int i_start = 10000 * id / cnt;
   int i_end = 10000 * (id+1) / cnt;
   langwierige_berechnung(A, i_start, i_end);
}
```

for

- Aufteilung von Schleifeniteration mit for
 - OpenMP teilt Iterationen den einzelnen Threads zu
 - Nur for-Schleifen mit bestimmter Syntax

```
double A[elemente];
#pragma omp parallel for
for (int i = 0; i < 10000; ++i)
   A[i] = langwierige_berechnung(i);</pre>
```

Seit OpenMP 3.0 sind auch Iterator-Schleifen parallelisierbar:

```
vector<int> v(10000);
typedef vector<int>::iterator iter;
#pragma omp parallel for
for (iter i = v.begin(); i < v.end(); ++i)
    langwierige_berechnung(*i);</pre>
```

for (II)

- Einschränkungen
 - Nur ganzzahlige Schleifenvariablen (mit oder ohne Vorzeichen)
 - Test nur mit <, <=, >, >=
 - Schleifenvariable verändern: nur einfache Ausdrücke
 - Operatoren ++, --, +, +=, -=
 - Obere und untere Grenze unabhängig von Schleifendurchlauf
 - Ausdrücke sind möglich
- Automatische Synchronisation nach for mit Barriere
 - kann mit **nowait** unterdrückt werden

for (III)

- Verschiedene Arten, den Indexraum auf Threads zu verteilen
- Auswahl erfolgt mit schedule
 - schedule(static[,k])
 - Indexraum wird in Blöcke der Größe k zerlegt und den Threads reihum zugewiesen
 - k=1: 012012012.....0
 - k=5: 000001111122222000001111122222...00000
 - schedule(dynamic[,k])
 - Indexraum wird in Blöcke der Größe k zerlegt und den Threads nach Bedarf zugewiesen
 - schedule(guided[,k])
 - Indexraum wird in Blöcke **proportional zur Restarbeit** auf Threads aufgeteilt und nach Bedarf zugewiesen; k = minimale Iterationszahl
 - schedule(auto)
 - Implementierung-spezifisch (Standard, wenn keine Angabe)
 - schedule(runtime)
 - Entscheidung zur Laufzeit (omp_set_schedule, omp_get_schedule, OMP_SCHEDULE)

Klauseln

Festlegen der Anzahl der Threads:

```
double A[10000];
#pragma omp parallel for num_threads(4)
for (int i = 0; i < 10000; ++i)
   A[i] = langwierige_berechnung(i);</pre>
```

- Alternativ ginge auch omp_set_num_threads(4);
- Oder über Umgebungsvariable export OMP_NUM_THREADS=4
- Bedingte Parallelisierung:

```
double A[elemente];
#pragma omp parallel for if (elemente > 100)
for (int i = 0; i < elemente; ++i)
   A[i] = langwierige_berechnung(i);</pre>
```

Mehrdimensionale Schleifen

- Zusammenfassung von Schleifen
 - for-Direktive wirkt nur auf n\u00e4chste Schleife
 - collapse(k) kombiniert Indexraum der folgenden k Schleifen
- Beispiel: Matrixmultiplikation

```
#pragma omp parallel for collapse(3)
for (int i = 0; i < dim1; ++i)
  for (int j = 0; j < dim2; ++j)
    for (int k = 0; k < dim3; ++k)
        C[i][j] = A[i][k]*B[k][j];</pre>
```

sections

- Parallelisierung ohne Schleifen mit Abschnitten
 - Jedem Abschnitt wird ein Thread zugewiesen
 - Nur statische Parallelität möglich: Abschnitt gilt für ganzes Team

```
#pragma omp parallel
#pragma omp sections
{
    #pragma omp section
    arbeit1();
    #pragma omp section
    arbeit2();
    #pragma omp section
    arbeit3();
}
```

sections (II)

- Rekursionen sind mit **sections** sehr einfach parallelisierbar
 - Beispiel: Quicksort mit verschachtelten Teams:

task

- Parallelisierung ohne Schleifen mit Tasks (OpenMP 3.0)
 - Jeder Task wird (reihum) einem Thread zugewiesen
 - Unterschied zu sections
 - Definition eines Tasks an beliebiger Stelle von beliebigem Thread im Team
 - Ein Thread im Team führt den Task aus

```
void quicksort(int a[], int l, int r)
{
    if (l < r)
    {
        int i = partition(a, l, r);
        #pragma omp task
        quicksort(a, l, i - 1);
        quicksort(a, i + 1, r);
    }
}</pre>
```

```
int main()
{
    #pragma omp parallel
    {
        #pragma omp single
        quicksort(a, 1, 99);
    }
}
```

Synchronisation

- Block der nur von einem / dem Master Thread im Team ausgeführt werden soll
 - #pragma omp single / #pragma omp master
 - Beispiel: Datei einlesen, Textausgabe auf der Konsole
- Block der von jedem Thread einzeln (seriell) ausgeführt werden soll
 - #pragma omp critical
 - Analog zur Mutex, entspricht dem Bereich zwischen lock und unlock
 - Beispiel: Zugriff auf gemeinsame Datenstruktur / Resource
- Atomares Schreiben ("kleiner kritischer Abschnitt")
 - #pragma omp atomic
 - Beispiel: Inkrementieren eines globalen Zählers
- Synchronisation aller Threads mit Barriere
 - #pragma omp barrier

master, barrier

```
int main()
   int a[5];
    #pragma omp parallel
       #pragma omp for
       for (int i = 0; i < 5; i++) a[i] = i * i;
       #pragma omp master
       for (int i = 0; i < 5; i++)
           std::cout << a[i] << std::endl;</pre>
       #pragma omp barrier
       #pragma omp for
       for (int i = 0; i < 5; i++) a[i] += i;
```

atomic, critical

```
void max zeros(int *a, int size)
    int max = a[0]; int zeros = 0;
    #pragma omp parallel for num threads(4)
    for (int i = 0; i < size; i++)
       if (a[i] == 0)
           #pragma omp atomic
            zeros++;
       if (a[i] > max)
        #pragma omp critical
           if (a[i] > max) max = a[i];
    std::cout << max << zeros << std::endl;</pre>
}
```

Speicherklauseln für Variablen

shared

Daten sind für alle Threads sichtbar/änderbar. Standard in Schleifen.

private

 Jeder Thread hat eigene Kopie. Daten werden nicht initialisiert. Sind außerhalb des parallelen Abschnitts nicht bekannt.

firstprivate

private Daten. Initialisierung mit letztem Wert vor parallelem Abschnitt

lastprivate

 private Daten. Der Thread, der die letzte Iteration ausführt, übergibt den Wert aus dem parallelen Abschnitt an das Hauptprogramm.

threadprivate

 globale Daten, die im parallelen Programmabschnitt jedoch als privat behandelt werden. Der globale Wert wird über den parallelen Abschnitt hinweg bewahrt.

reduction

private Daten, werden am Ende auf einen globalen Wert zusammengefasst.

BEMERKUNGEN ZUR P-AUFGABE

Bemerkungen zu Aufgabe 3

- Typischer Fehler:
 - Variable-length Arrays sind nicht Teil des C++ Standards

```
int rows = 5;
int cols = 10;
int matrix [rows][cols];
```



```
int rows = 5;
int cols = 10;

vector<int> matrix(rows*cols);
```

delete anstatt delete[]



```
int *matrix = new int[rows*cols];
// ...
delete matrix;
```



```
int *matrix = new int[rows*cols];

// ...
delete[] matrix;
```

Bemerkungen zu Aufgabe 3 (II)

- Mögliche Verbesserungen:
 - Auf die Traceback-Matrix kann auch verzichtet werden
 - Traceback-Matrix speichert Richtung, aus der das Maximum kam
 - Alternativ kann man die Richtung des Traceback während des Zurückverfolgens berechnet werden
 - Funktionen wie score oder max als inline definieren
 - Eine Matrix-Klasse programmieren
 - https://svn.mi.fu-berlin.de/agbio/aldabi/ws11/documents/aufgabe3/matrix.h

Hinweise zu Aufgabe 4

- Was passiert, wenn der Text einfach nur in nichtüberlappende Teile zerlegt wird?
 - Matches, die halb in beiden Teilen liegen, werden nicht gefunden

what ever whateve r

- Wie muss der Text aufgeteilt werden, damit
 - Alle Matches gefunden werden
 - Keine Matches doppelt ausgegeben werden

• Wie verhindert man, dass 2 Threads gleichzeitig den vector mit Matches beschreiben