Parallelprogrammierung – Einstieg

Johannes Brauer

Created: 2017-10-01 Sun 19:53


Warum Parallelprogrammierung?



Technische Gründe

- Erhöhung der Rechenleistung durch Erhöhung der Taktfrequenzen stösst technisch an Grenzen
- Mooresche Gesetz gilt aber noch.
- Folge: Prozessoren mit mehreren Kernen.
- Leistungssteigerung durch Parallelarbeit
- ullet Geschwindigkeitssteigerung bei n Kernen theoretisch n-fach
 - praktisch nicht erreichbar
 - Anwendungsentwicklung auf Parallelprogrammierung nicht vorbereitet

Enwicklung der Mikroprozessortechnik



Robert C. Martin: The failure of state

Functional Programming – The Failure of State

Ausschnitte:

- 34:34 fewer concurrency issues
- 36:12 Moore's law bis 43:47
- 49:44 OO = procedure + state bis 50:56
- 53:57 impose discipine on the change of state bis 55:12


Prozesse, Threads, Synchronisation

(Die Ausführungen in diesem lehnen sich an ein Vorlesungsskript von Uwe Neuhaus an)

Bestandteile von Computersystemen

- 1. Hardware Bereitstellung grundlegender Betriebsmittel (Prozessor, Speicher, Ein-/Ausgabegeräte)
- 2. Betriebssystem steuert und koordiniert die Nutzung der Betriebsmittel für die verschiedenen Anwendungsprogramme der verschiedenen Anwender
- 3. Anwendungsprogramme definieren, wie das zu bearbeitende Problem mit Hilfe der Betriebsmittel gelöst wird (Compiler, Datenbanksysteme, Textverarbeitung, Spiele usw.)
- 4. Anwender (Menschen, Maschinen, andere Computer)


Abstrakte Sicht der Bestandteile



Mehrprogrammbetrieb


Stapelverarbeitung

Mehrere Aufträge werden im Speicher gehalten. Der Prozessor wechselt zwischen diesen Aufträgen hin und her.




CPU-Aufteilung

Ablauf eines Programms:



quasi-paralleler Ablauf zweier Programme:



Benötigte Betriebssystemfähigkeiten beim Mehrprogrammbetrieb

- Bereitstellung von Ein-/Ausgabe-Routinen
- Zuordnung von Geräten zu Aufträgen
- Speicherverwaltung das Betriebssystem muss den verschiedenen Aufträgen Speicher zuordnen
- Prozessor-Scheduling das Betriebssystem muss zwischen den verschiedenen, ausführbereiten Aufträgen auswählen
- Schutz vor Programmfehlfunktionen (Übergriffen eines Auftrags auf einen anderen, Endlosschleifen usw.)

Mehrbenutzersystem (Time-Sharing Systems) – Interaktive Benutzung

- Eine interaktive Kommunikationsmöglichkeit zwischen dem Anwender und der Computersystem wird bereitgestellt, die den Zugriff auf Programme und Daten erlaubt. Nach der Abarbeitung eines Kommandos wird das nächste Benutzerkommando erwartet.
- Der Prozessor wird in schneller Abfolge zwischen verschiedenen Aufträgen, die sich im Speicher und auf Festplatte befinden, hin und her geschaltet. (Nur Aufträge im Speicher erhalten den Prozessor.)
- Ein Auftrag wird in den Hauptspeicher ein- oder auf Festplatte ausgelagert.

Arbeitsplatzrechnersysteme / Personal-Computer

- Personal-Computer Computersysteme, die ausschließlich einem einzigen Benutzer zur Verfügung stehen
- Ein-/Ausgabegeräte Tastatur, Maus, Monitor, kleiner Drucker, ...
- Komfortable Bedienung, schnelle Reaktionszeit
- Konzepte größerer Betriebssysteme können verwendet werden (z.B. Time-Sharing). Andere Aspekte u.U. weniger wichtig (z.B. Prozessor-Auslastung). Ausführung verschiedener Betriebssysteme möglich (Windows, MacOS, UNIX, Linux)

Mehrprozessorsysteme

Prinzip

- Mehrprozessorsysteme besitzen mehrere, eng gekoppelte Prozessoren
- Eng gekoppelt Prozessoren nutzen gemeinsam Hauptspeicher und Systemtakt. Die Kommunikation zwischen den Prozessoren findet üblicherweise über den gemeinsam genutzten Speicher statt.
- Vorteile von Mehrprozessorsystemen: Erhöhter Durchsatz
 - Verbessertes Preis/Leistungsverhältnis
 - Höhere Zuverlässigkeit
 - stufenweiserLeistungsverlust(gracefuldegradation) •
 - Ausfallsicherheit(fail-softsystems)

Varianten


Symmetric multiprocessing (SMP)

- Auf jedem Prozessor läuft das identische Betriebssystem
- Mehrere Prozesse können ohne Leistungsverlust ablaufen
- Die meisten modernen Betriebssysteme unterstützen SMP

Asymmetric multiprocessing

- Jeder Prozessor hat eine spezielle Aufgabe. Ein Master-Prozessor verteilt Aufgaben an die anderen (möglicherweise spezialisierten) Slave- Prozessoren.
- Beispiel: Grafikprozessoren

Architektur bei symmetrischen Mehrprozessorsystemen



Achtung: Zugriff auf den Hauptspeicher über gemeinsamen Bus kann zum Flaschenhals werden.

Prozesse

Für die Behandlung der Anforderungen in Mehrprogrammbetriebssystemen sind primitive Ad-hoc-Lösungen nicht mehr möglich. Das Verständnis des Gesamtsystems ist nicht mehr durch die Beschreibung des Verhaltens der CPU zu jedem Zeitpunkt möglich, da das Verhalten der CPU in Mehrbenutzersystemen im Mehrprogrammbetrieb stark von nicht vorhersagbaren externen Ereignissen (Unterbrechungen) abhängig ist. Das Betriebssystem wird als Ansammlung von funktionellen Einheiten betrachtet, die zunächst unabhängig voneinander arbeiten aber über wohldefinierte Schnittstellen miteinander kommunizieren müssen. Diese funktionellen Einheiten bezeichnet man als **Prozesse**.

Prozessbegriff

Typische Merkmale von Prozessen:

- brauchen Prozessor
- enthalten jeweils ein sequentielles Programm
- können grundsätzlich parallel ablaufen

Zur Abgrenzung zum Begriff *Benutzerauftrag* (*Job*): Zur Abarbeitung eines Benutzerauftrags sind in der Regel mehrere Prozesse notwendig.

Formen der Parallelität

- mehrere Prozesse laufen auf unterschiedlichen Prozessoren ab (tatsächlich parallel)
- ein Prozessor wird "scheibchenweise" den Prozessen zugeordnet, sodass diese "überlappt" ablaufen (quasi-parallel)

Die im Zusammenhang mit der Parallelität von Prozessen auftretenden Probleme sind davon aber unabhängig.

Synchronisation konkurrierender Prozesse

	Problem des	wechselseitigen	Ausschlusses
--	-------------	-----------------	--------------

Das Problem des wechselseitigen Ausschlusses (*mutual exclusion*) wurde erstmals 1965 von Edsger W. Dijkstra formuliert.

Beispiel 1:

Zwei zyklische Prozesse p_1 und p_2 benutzen von Zeit zu Zeit ein Magnetband. Es steht nur ein Gerät zur Verfügung, das nicht von mehr als einem Prozess gleichzeitig benutzt werden kann.

1. Lösungsversuch: Definition einer booleschen Variable frei

```
p_1:

001 wiederhole
002 wiederhole bis frei;
003 frei := false;
004 benutze(magnetband)
005 frei := true;
006 prei := true;
007 wiederhole bis frei;
008 wiederhole bis frei;
009 wiederhole bis frei;
000 wiederhole
000 frei := false;
000 frei := false;
000 benutze(magnetband)
000 frei := true;
```

Probleme:

- Wenn p_1 und p_2 parallel ablaufen, können sie auch gleichzeitig das Magnetband als frei erkennen. Das gleiche Problem kann auch bei quasi-parallel ablaufenden Prozessen auftreten, da jeder Prozess zwischen 002 und 003 unterbrochen werden kann.
- Durch die Warteschleife wird Prozessorzeit beansprucht (busy waiting).

2. Lösungsversuch: Definition einer booleschen Variable planderReihe

```
p<sub>1</sub>:
                                           p<sub>2</sub>:
001 wiederhole
                                           001 wiederhole
                                                  wiederhole bis nicht planderReihe;
002
       wiederhole bis planderReihe;
                                           002
003
      benutze(magnetband)
                                           003
                                                 benutze(magnetband)
      planderReihe := false;
                                                  planderReihe := true;
004
                                           004
FFF ständig
                                           FFF ständig
```

Ein wechselseitiger Ausschluss ist zwar gewährleistet, allerdings müssen die Prozesse das Magnetband abwechselnd benutzen. Beide Prozesse müssen außerdem "am Leben" bleiben. Busy waiting tritt auch hier auf.

3. Lösungsversuch: Definition zweier boolesche Variablen plistdran und plistdran

Initialisierung:

```
plistdran := false
p2istdran := false
p_1:
                                       p_2:
                                       wiederhole
wiederhole
   plistdran := true
                                          p2istdran := true
   wiederhole bis nicht p2istdran
                                          wiederhole bis nicht plistdran
   benutze(magnetband)
                                          benutze(magnetband)
   plistdran := false
                                          p2istdran := false
ständig
                                       ständig
```

Wechselseitiger Ausschluss ist zwar garantiert, es besteht aber die Gefahr der Verklemmung (deadlock).

Anforderungen an eine Lösung für das Problem des wechselseitigen Ausschlusses:

- 1. Das Betriebsmittel wird nach endlicher Zeit zugewiesen.
- 2. Ein Prozess gibt das Betriebsmittel nach endlicher Zeit wieder frei.
- 3. Ein Prozess, der wartet, soll keine Rechenzeit verbrauchen.
- 4. Eine Problemlösung soll von den Prozessen in eine gemeinsame Umgebung verlagert werden.

Das grundsätzliche Problem resultiert aus der "unkontrollierten" Benutzung gemeinsamer Betriebsmittel. Weitere Beispiele für das Auftreten des Problems des wechselseitigen

Ausschlusses:

- 1. Veränderung von Datensätzen in einer von mehreren Prozessen gemeinsam benutzten Datei
- 2. gemeinsame Benutzung von Unterprogrammen mit lokalen Variablen für Zwischenergebnisse



Definition (kritischer Abschnitt):

Programmabschnitte, in denen sich zu einem Zeitpunkt nur jeweils ein Prozess befinden darf, heißen kritische Abschnitte (critical sections).

Prof. Dr.-ing. Johannes Brauer. Programmerparadigmen

Lösung: P- und V-Operationen nach Edsger W. Dijkstra

P und V sind zwei Operationen auf einer gemeinsamen Variablen, genannt *Semaphorvariable*. Jedem kritischen Abschnitt wird eine Semaphore zugeordnet.

Definition von P und V:

Prof. Dr.-ing. Johannes Brauer. Programmerparadigmen

Beispiel für die Sicherung eines kritischen Abschnitts (Benutzung eines Magnetbandgeräts) ...

... durch eine Semaphore s:

```
P(s)
benutze(magnetband)
V(s)
```

Eigenschaften von P und V:

- sind selbst kritische Abschnitte
- müssen atomar sein (dürfen nicht selbst unterbrochen werden)
- Es handelt sich aber um kurze kritische Abschnitte, die im Systemkern realisiert werden, wo wechselseitiger Ausschluss einfach zu implementieren ist.
- Sie werden häufig mithilfe eines Spezialbefehls des Prozessors realisiert, wobei ein aktives Warten in Kauf genommen wird.
- Dazu wird eine Sperrvariable pv mit folgender Bedeutung eingeführt:

```
pv=1: P- und V-Operationen können ausgeführt werden
```

pv=0: P- und V-Operationen können nicht ausgeführt werden

```
Der Spezialbefehl teste_und_setze(pv)
```

... ist eine unteilbare Operation, die folgendermaßen arbeitet:

```
wiederhole solange pv = 0; (* tue nichts, busy waiting *) pv := 0
```

Mithilfe dieses Befehls werden nun zwei modifizierte Operationen P' und V' eingeführt, die dann zur Sicherung eines kritischen Abschnitts eingesetzt werden können.

Alternative Realisierung für Semaphore

- S ist ein Semaphoren-Objekt mit den Methoden wait() (möchte passieren) und signal() (verlassen).
- Ein Semaphoren-Objekt ist meist verbunden mit einer zugehörigen Prozess-Warteschlange W.

Prozess 1

```
S.wait();
i = leseZaehler();
i = i + 10;
schreibeZaehler( i );
S.signal();
```

Prozess 2

```
S.wait();
j = leseZaehler();
j = j - 5;
schreibeZaehler( j );
S.signal();
```

S.wait():

Realisierung eines binären Semaphors


```
if ( TestAndSet(belegt) ) {
   Prozess in Warteschlange W einreihen;
   Prozess in Zustand "wartend" versetzen;
S.signal():
if ( W.empty() == false ) {
  Einen Prozess aus Warteschlange W lösen;
   Prozess in Zustand "bereit" versetzen;
else { belegt = false; }
```

Realisierung eines Zähl-Semaphors

```
S.wait():
if ( FetchAndAdd( zaehler, -1 ) < 1) {</pre>
   Prozess in Warteschlange W einreihen;
   Prozess in Zustand "wartend" versetzen;
S.signal():
if ( FetchAndAdd( zaehler, 1 ) < 0 ) {</pre>
   Einen Prozess aus Warteschlange W lösen;
   Gelösten Prozess in Zustand "bereit" versetzen;
```

Synchronisation kooperierender Prozesse

- Bisher wurden nur um gemeinsame Betriebsmittel konkurrierende Prozesse betrachtet, die sonst nichts miteinander zu tun hatten.
- Kooperation zwischen Prozessen kann z.B. heißen, dass Nachrichten zwischen einem Erzeuger und einem Verbraucher ausgetauscht werden (producer-consumer-problem).
- Nachrichtenaustausch soll gepuffert erfolgen, um Erzeuger und Verbraucher bezüglich ihrer Arbeitsgeschwindigkeit zu entkoppeln.
- Ringpuffer fester Größe kann nur eine feste Anzahl von Nachrichten speichern.
- Abbildung zeigt einen teilweise gefüllten Ringpuffer mit zwei Zeigern, c



für den Verbraucher und p für den Erzeuger.

• Beide Prozesse bearbeiten den Puffer im Uhrzeigersinn. Durch die Prozesssynchonisation muss verhindert werden, dass sie sich gegenseitig "überholen".

Sychronisation von Erzeuger un Verbraucher durch Semaphore

 Die Prozesse benutzen jeweils eine Kommunikationsprozedur,
 SendeNachricht und EmpfangeNachricht, die dafür sorgen, dass der Erzeuger wartet, wenn der Puffer voll ist, und der Verbraucher, wenn der Puffer leer ist.

Konsument

```
EmpfangeNachricht(puffer)
while (true) {
   belegt.wait();
   mutex.wait();
   nachricht = holeAusPuffer();
   mutex.signal();
   frei.signal();
   konsumiere(nachricht);
}
```

Produzent

```
SendeNachricht(puffer)
while (true) {
   nachricht = erzeuge();
   frei.wait();
   mutex.wait();
   schreibeInPuffer(nachricht);
   mutex.signal();
   belegt.signal();
}
```

Initialisierung: mutex.zaehler = 1; frei.zaehler = max;
belegt.zaehler = 0;

Nachteil dieser Lösung

- Die Verantwortung für die korrekte Synchronisation bzw. deren korrekte Programmierung liegt bei den Prozessen.
- Programmierfehler können dabei zu schwer reproduzierbarem Fehlverhalten (z.B. Verklemmungen) führen.

Weitere klassische Synchronisationsprobleme

Readers-Writers-Problem

- Einige Prozesse/Threads wollen einen Datenbereich lesen, einige wollen ihn verändern.
- Gleichzeitiger Lesezugriff ist erlaubt.
- Schreibzugriffe müssen exklusiv erfolgen.

Dining-Philosophers-Problem

- Fünf Philosophen sitzen um einen runden Tisch, denken nach und essen Reis mit Stäbchen.
- Zwischen den Tellern liegt jeweils ein Stäbchen, zum Essen braucht man aber zwei.

Monitore

- Programmiersprachliches Konstrukt, funktional äquivalent zu Semaphoren
- Kritische Methoden und Daten werden in einer Klasse mit einem zugehörigen Semaphor kombiniert.
- Leichter zu handhaben, weniger fehleranfällig
- Unterstützung der Synchronisation durch Bedingungsvariablen

Synchronisation durch Nachrichtenaustausch

- Die bisher betrachteten Synchronisationsprimitive sind nur einsetzbar, wenn die beteiligten Prozesse Zugriff auf einen gemeinsamen Speicherbereich (shared memory) haben, in dem sich z.B. die Semaphorvariablen befinden.
- Auf diese Art ist daher die Synchronisation in Verteilten Systemen, wo Prozesse auf unterschiedlichen Maschinen ablaufen können, nicht möglich.
- Hierfür werden neue Synchronisationsprimitive (Aufrufe des Systemkerns), die auf dem Austausch von Nachrichten (message passing) basieren, eingeführt:

```
send(destination, message)
receive(source, message)
```

- Mit send und receive können Prozesse synchronisiert werden, die auf Prozessoren ohne gemeinsamen Speicher ablaufen.
- Bei einem Aufruf von send wird der Prozess blockiert, wenn keine Nachricht übermittelt werden kann. Bei einem Aufruf von receive wird der Prozess blockiert, wenn keine Nachricht verfügbar ist.

Mögliche Schwierigkeiten bei der Nachrichtenübermittlung:

- Verlust einer Nachricht
 Abhilfe: jede gesendete Nachricht muss quittiert werden
 (acknowledgement), wiederholen der Nachricht beim Ausbleiben der
 Quittung
- Verlust der Quittung
- doppeltes Eintreffen einer Nachricht beim Empfänger Abhilfe: Numerieren der Nachrichten
- Eindeutige Benennung (Adressierung) von:
 - Prozessoren
 - Maschinen
 - domains
- Sicherheitsprobleme
- Effizienz, wenn Sender und Empfänger auf der gleichen Maschine laufen

Behandlung des *Producer-Consumer-Problems* mit *message passing*.

Annahmen:

- Nachrichten haben feste Länge.
- Gesendete, aber noch nicht empfangene Nachrichten werden vom Betriebssystem automatisch gepuffert.
- Maximal max Nachrichten können gepuffert werden.

```
Consumer:
    for i := 1 to max do send(producer,emptymessage);
    while true do begin
       receive(producer, message);
       extract data(message);
       send(producer,emptymessage);
       process(data);
    end
Producer:
    while true do begin
       produce data(data);
       receive(consumer,emptymessage);
       build message(message,data);
       send(consumer, message);
    end
```

Prof. Dr.-ing. Johannes Brauer. Programmerparadigmen

Anmerkungen:

- Die Zahl der Nachrichten bleibt konstant.
- Für Pufferung ist ein fester Speicherbereich vorgesehen.
- Pufferung und Adressierung erfolgt durch sog. mailboxes bei Sender und Empfänger.
- in UNIX entsprechen sogenannte pipes den mailboxes.

Threads


Prozesse und Threads

Prozess

- ein in Ausführung befindliches Programm
- benötigt Ressourcen: Prozessor, Speicher (Programmcode, Daten, Stack), Dateien, E/A-Geräte
- bislang betrachtet: sequentiell arbeitende Prozesse (nur ein Ausführungsstrang)

Thread

- ein Ausführungsstrang innerhalb eines Prozesses
- benötigt: Prozessor, eigenen Stack
- nutzt: Programmcode, Daten, Dateien, E/A-Geräte des Prozesses
- Mehrere Threads innerhalb eines Prozesses möglich



Beispiele für Multithreading

- Anwendungen mit graphischer Benutzeroberfläche, z.B. Textverarbeitung:
 - Texteingabe
 - Rechtschreibprüfung
 - Ausdruck
- Serversoftware, z.B. Webserver, DB-Server:
 - Administration
 - Simultane Bearbeitung vieler Anfragen

Vorteile von Multithreading

Kürzere Antwortzeiten

Bei interaktiven Anwendungen kann auch auf Benutzereingaben reagiert werden, während andere, langandauernde Aufgaben durchgeführt werden.

Gemeinsame Nutzung von Ressourcen

Auf gemeinsamen Speicher sowie gemeinsame Dateien und E/A-Geräte kann ohne weiteren Aufwand zugegriffen werden.

Wirtschaftlichkeit

Die Erzeugung eines neuen Threads und der Wechsel zwischen zwei Threads eines Prozesses verursacht erheblich weniger Auf- wand (im Vergleich zur Prozesserzeugung/zum Prozesswechsel).

Nutzung von Multiprozessorarchitekturen

Auch ein einziger multithreading Prozess kann gleichzeitig mehrere Prozessoren nutzen.

Anwender- und Kernel-Threads

Anwender-Threads

Erzeugung, Scheduling und Verwaltung der Threads erfolgt über spezielle Programm-Bibliotheken auf Ebene des

Anwendungsprogramms. Für den Kernel besteht das Programm aus einem einzigen, single-threaded Prozess.

Vorteil

effizient (Kernel muss nicht eingreifen)

Nachteil

Muss ein Thread warten, müssen es alle.

Kernel-Threads

Erzeugung, Scheduling und Verwaltung der Threads werden durch das Betriebssystem unterstützt.

Vorteile

Verteilung auf mehrere Prozessoren möglich; ein wartender Thread behindert die anderen Threads nicht.

Nachteil

Prof. Dr.-Ing. Johanne Etwas Jangsamer als Anwender-Threads.

Multithreading-Modelle

Many-to-One-Modell

- Mehrere Anwender-Threads werden auf einen Kernel-Thread abgebildet.
- Beispiele: Green-Thread-Library bei Solaris 2, POSIX Pthread-Library, Betriebssysteme ohne Thread-Unterstützung


One-to-One-Modell

- Jeder Thread eines Anwendungsprogramms wird auf genau einen Kernel-Thread abgebildet
- Beispiele: Windows NT, Windows 2000, OS/2


Many-to-Many-Modell

- Die Threads der Anwendungsprogramme werden auf eine Anzahl von Kernel-Threads gemultiplext.
- Beispiele: IRIX, HP-UX, Tru64 UNIX


Multithreading-Modelle: Many-to-One



Multithreading-Modelle: One-to-One



Multithreading-Modelle: Many-to-Many



Verklemmungen

Definition:

Eine Verklemmung (*deadlock*) bedeutet, dass zwei oder mehr Prozesse auf Ereignisse warten, die niemals eintreten werden ("Nach-Ihnen-Nach-Ihnen"-Schleifen, warten im "Kreis").

Beispiel: Verschachtelung von kritischen Abschnitten

Das Auftreten von Verklemmungen ist zeitabhängig. Ursachen sind im laufenden System schwer feststellbar und nicht ohne weiteres reproduzierbar.

Vier notwendige und hinreichende Bedingungen für das Auftreten von Verklemmungen:

"Wechselseitiger Ausschluss"-Bedingung

Ein Betriebsmittel, um das Prozesse konkurrieren, ist entweder frei oder genau einem Prozess zugewiesen.

"Halte-und-warte"-Bedingung

Prozesse mit bereits zugewiesenen Betriebsmitteln dürfen weitere Betriebsmittel anfordern (hold and wait).


"Kein-Entzug"-Bedingung

Prozesse geben Betriebsmittel nur von sich aus frei. Betriebsmittel können ihnen nicht zwangsweise entzogen werden.

"Zirkuläres-Warten"-Bedingung

Zwei oder mehr Prozessse warten wechselseitig auf Betriebsmittel, die von dem/den jeweils anderen gehalten werden.

Die vierte Bedingung wird, wie in Abbildung gezeigt, zur Modellierung von Verklemmungssituationen durch Graphen zum Zwecke der Verklemmungserkennung benutzt.



Vier Strategien mit dem Verklemmungsproblem umzugehen:

- Verklemmungen unmöglich machen
- Verklemmungen vermeiden
- Verklemmungen erkennen und beseitigen
- Verklemmungen ignorieren

Verklemmungen unmöglich machen

- Wechselseitigen Ausschluss verhindern (Bedingung 1 ist aufgehoben)
 - Z. B. Einrichten eines Druckerdaemonen
 - Probleme: nicht f
 ür alle Betriebsmittel geeignet, nur Verlagerung auf andere Betriebsmittel
- Zusätzliche Betriebsmittelanforderungen verbieten (Bedingung 2 ist aufgehoben)
 - Z. B. Anforderung aller benötigten Betriebsmittel zu Prozessbeginn
 - Probleme: Unnötig lange Belegung der Betriebsmittel, schlechte Betriebsmittelauslastung

- Vorzeitige Betriebsmittelrückgabe erzwingbar machen (Bedingung 3 ist aufgehoben)
 - Z.B. Entzug nach einer bestimmten Zeit
 - Bei CPU selbstverständlich, bei E/A-Geräten meist nicht sinnvoll.
 - Probleme: muss ggf. auf Programmebene berücksichtigt werden, bereits geleistete Arbeitsleistung geht verloren
- Zirkularität unterbinden (Bedingung 4 ist aufgehoben)
 - Z. B. lineare oder hirarchische Ordnung der Betriebsmittel,
 Anforderungen dann nur gemäß dieser Ordnung
 - Probleme: keine allgemein brauchbare Ordnung angebbar, deshalb oft schlechte Auslastung

Verklemmungsvermeidung

beruht auf der Grundidee, die Betriebsmittelanforderungen der Prozesse in eine "verklemmungsfreie" Reihenfolge zu bringen. Die Algorithmen (Vgl. Bankiersalgorithmus) hierfür sind teiweise sehr komplex und auch nur anwendbar, wenn der gesamte Betriebsmittelbedarf der Prozesse im Vorhinein bekannt ist, was in der Praxis häufig nicht der Fall ist. Nichtsdestotrotz hat sich um dieses Thema herum eine eigene mathematische Theorie entwickelt, auf die hier aber nicht eingegangen wird.

Bankiersalgorithmus

- Betrachtung der Betriebsmittelanforderungen als gleichzeitig auftretende Maximalforderungen
- Unterscheidung von
 - sicheren Zuständen (Verklemmung nicht möglich)
 - unsicheren Zuständen (Verklemmung nicht zwingend, bei ungünstiger Anforderungsreihen- folge aber möglich)
- Weitere Prozesse werden nur gestartet, wenn kein unsicherer Zustand entsteht.
- Auf die Darstellung weiterer Details wird hier verzichtet.

Probleme der Verklemmungsvermeidung

- I. A. Zahl der maximal benötigten Betriebsmittel unbekannt
- Ständig wechselnde Zahl von Prozessen
- Zahl der verfügbaren Betriebsmittel ebenfalls veränderlich
- Algorithmus ist laufzeit- und speicherintensiv

Prof. Dr.-ing. Johannes Brauer. Programmerparadigmen

Verklemmungen erkennen

- Analyse bei verdächtigen Symptomen:
 - viele Prozesse warten und der Prozessor ist unbeschäftigt
 - mindestens zwei Prozesse warten zu lange auf Betriebsmittel
- Bei Verdacht Start eines Erkennungsalgorithmus
 - B. Zyklen-Erkennung im Betriebsmittelgraphen

Verklemmungen beseitigen

- Prozesse abbrechen
- Prozesse zurücksetzen
- Betriebsmittel entziehen
- Probleme:
 - Prozess-/Betriebsmittelauswahl
 - Verlust bereits geleisteter Arbeit
 - Mögliche Inkonsistenzen
 - U. U. manueller Mehraufwand erforderlich

Verklemmungen ignorieren

- Erkennung von Verklemmungen aufwendig
- Beseitigung von Verklemmungen nicht unproblematisch
- Vermeidung bzw. Unmöglichmachen von Verklemmungen u. U. wenig effizient
- Verklemmungen sind in der Regel nicht das dringlichste Problem

verwendete Literatur

- Bengel2015
- CACM2017
- CACM2016
- Subramanian2017

Literaturverzeichnis

- [Bengel2015] Günther Bengel, Christian Baun, Marcel Kunze & Karl-Uwe Stucky, Masterkurs Parallele und Verteilte Systeme, Springer Fachmedien Wiesbaden (2015).
- [CACM2017] Practical Parallelism, (2017), zuletzt aufgerufen am 26.09.2017: https://cacm.acm.org/careers/219104-practical-parallelism/fulltext
- [CACM2016] Parallel Programming Made Easy, (2017), zuletzt aufgerufen am 26.09.2017: https://cacm.acm.org/careers/203794-parallel-programming-made-easy/fulltext
- [Subramanian2017] Subramanian, Jeffrey, Abeydeera, Lee, Ying, Emer & Sanchez, Fractal: An Execution Model for Fine-Grain Nested Speculative Parallelism, 587-599, in in: Proceedings of the 44th Annual International Symposium on Computer Architecture, edited by ACM