Parallelprogrammierung – Einstieg

Johannes Brauer

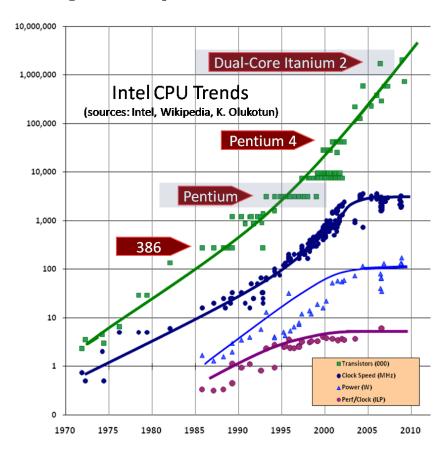
October 2, 2017

Warum Parallelprogrammierung?

Technische Gründe

- Erhöhung der Rechenleistung durch Erhöhung der Taktfrequenzen stösst technisch an Grenzen
- Mooresche Gesetz gilt aber noch.
- Folge: Prozessoren mit mehreren Kernen.
- Leistungssteigerung durch Parallelarbeit
- \bullet Geschwindigkeitssteigerung bei nKernen theoretisch n-fach
 - praktisch nicht erreichbar
 - Anwendungsentwicklung auf Parallelprogrammierung nicht vorbereitet

Enwicklung der Mikroprozessortechnik



Robert C. Martin: The failure of state

 $\label{eq:Functional Programming - The Failure of State} Ausschnitte:$

- 34:34 fewer concurrency issues
- 36:12 Moore's law bis 43:47
- 49:44 OO = procedure + state bis 50:56
- 53:57 impose discipine on the change of state bis 55:12

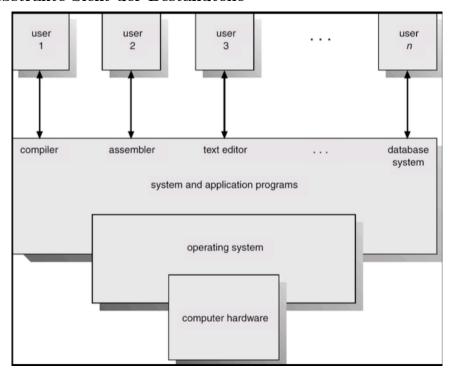
Prozesse, Threads, Synchronisation

(Die Ausführungen in diesem lehnen sich an ein Vorlesungsskript von Uwe Neuhaus an)

Bestandteile von Computersystemen

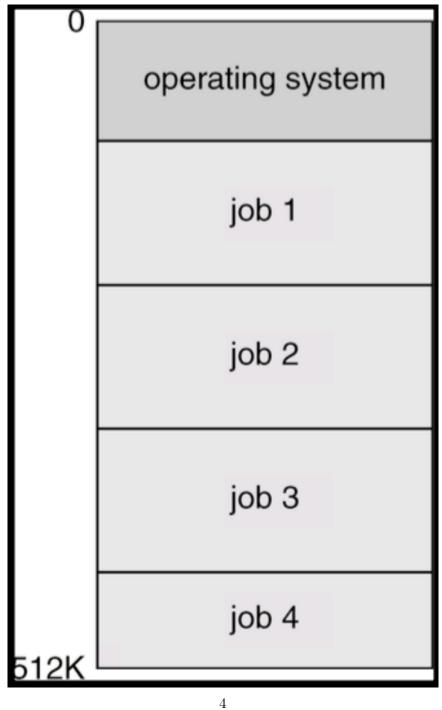
- 1. Hardware Bereitstellung grundlegender Betriebsmittel (Prozessor, Speicher, Ein-/Ausgabegerate)
- 2. Betriebssystem steuert und koordiniert die Nutzung der Betriebsmittel fur die verschiedenen Anwendungsprogramme der verschiedenen Anwender
- 3. Anwendungsprogramme definieren, wie das zu bearbeitende Problem mit Hilfe der Betriebsmittel gelost wird (Compiler, Datenbanksysteme, Textverarbeitung, Spiele usw.)
- 4. Anwender (Menschen, Maschinen, andere Computer)

Abstrakte Sicht der Bestandteile



${\bf Mehrprogrammbetrieb}$

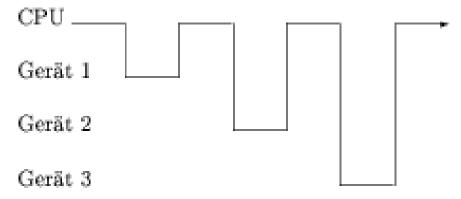
Stapelverarbeitung



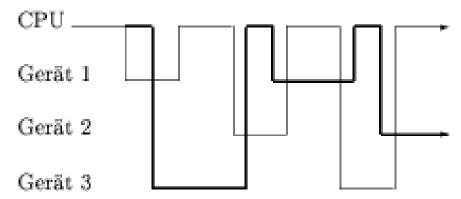
Mehrere Auftrage werden im Speicher gehalten. Der Prozessor wechselt zwischen diesen Auftragen hin und her.

CPU-Aufteilung

Ablauf eines Programms:



quasi-paralleler Ablauf zweier Programme:



Benotigte Betriebssystemfahigkeiten beim Mehrprogrammbetrieb

- Bereitstellung von Ein-/Ausgabe-Routinen
- Zuordnung von Geraten zu Auftragen
- Speicherverwaltung das Betriebssystem muss den verschiedenen Auftragen Speicher zuordnen
- Prozessor-Scheduling das Betriebssystem muss zwischen den verschiedenen, ausfuhrbereiten Auftragen auswahlen

• Schutz vor Programmfehlfunktionen (Ubergriffen eines Auftrags auf einen anderen, Endlosschleifen usw.)

Mehrbenutzersystem (Time-Sharing Systems) – Interaktive Benutzung

- Eine interaktive Kommunikationsmoglichkeit zwischen dem Anwender und der Computersystem wird bereitgestellt, die den Zugriff auf Programme und Daten erlaubt. Nach der Abarbeitung eines Kommandos wird das nachste Benutzerkommando erwartet.
- Der Prozessor wird in schneller Abfolge zwischen verschiedenen Auftragen, die sich im Speicher und auf Festplatte befinden, hin und her geschaltet. (Nur Auftrage im Speicher erhalten den Prozessor.)
- Ein Auftrag wird in den Hauptspeicher ein- oder auf Festplatte ausgelagert.

Arbeitsplatzrechnersysteme / Personal-Computer

- Personal-Computer Computersysteme, die ausschließlich einem einzigen Benutzer zur Verfugung stehen
- Ein-/Ausgabegerate Tastatur, Maus, Monitor, kleiner Drucker, ...
- Komfortable Bedienung, schnelle Reaktionszeit
- Konzepte großerer Betriebssysteme konnen verwendet werden (z.B. Time-Sharing). Andere Aspekte u.U. weniger wichtig (z.B. Prozessor-Auslastung). Ausfuhrung verschiedener Betriebssysteme moglich (Windows, MacOS, UNIX, Linux)

Mehrprozessorsysteme

Prinzip

- Mehrprozessorsysteme besitzen mehrere, eng gekoppelte Prozessoren
- Eng gekoppelt Prozessoren nutzen gemeinsam Hauptspeicher und Systemtakt. Die Kommunikation zwischen den Prozessoren findet ublicherweise uber den gemeinsam genutzten Speicher statt.
- Vorteile von Mehrprozessorsystemen: Erhohter Durchsatz

- Verbessertes Preis/Leistungsverhaltnis
- Hohere Zuverlassigkeit
 - * stufenweiserLeistungsverlust(gracefuldegradation) •
 - * Ausfallsicherheit(fail-softsystems)

Varianten

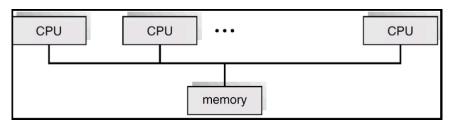
Symmetric multiprocessing (SMP) • Auf jedem Prozessor lauft das identische Betriebssystem

- Mehrere Prozesse konnen ohne Leistungsverlust ablaufen
- Die meisten modernen Betriebssysteme unterstutzen SMP

Asymmetric multiprocessing • Jeder Prozessor hat eine spezielle Aufgabe. Ein Master-Prozessor verteilt Aufgaben an die anderen (moglicherweise spezialisierten) Slave- Prozessoren.

• Beispiel: Grafikprozessoren

Architektur bei symmetrischen Mehrprozessorsystemen



Achtung: Zugriff auf den Hauptspeicher über gemeinsamen Bus kann zum Flaschenhals werden.

Prozesse

Für die Behandlung der Anforderungen in Mehrprogrammbetriebssystemen sind primitive Ad-hoc-Lösungen nicht mehr möglich. Das Verständnis des Gesamtsystems ist nicht mehr durch die Beschreibung des Verhaltens der CPU zu jedem Zeitpunkt möglich, da das Verhalten der CPU in Mehrbenutzersystemen im Mehrprogrammbetrieb stark von nicht vorhersagbaren externen Ereignissen (Unterbrechungen) abhängig ist. Das Betriebssystem wird als Ansammlung von funktionellen Einheiten betrachtet, die zunächst unabhängig voneinander arbeiten aber über wohldefinierte Schnittstellen miteinander kommunizieren müssen. Diese funktionellen Einheiten bezeichnet man als **Prozesse**.

Prozessbegriff

Typische Merkmale von Prozessen:

- brauchen Prozessor
- enthalten jeweils ein sequentielles Programm
- können grundsätzlich parallel ablaufen

Zur Abgrenzung zum Begriff Benutzerauftrag (Job): Zur Abarbeitung eines Benutzerauftrags sind in der Regel mehrere Prozesse notwendig.

Formen der Parallelität

- mehrere Prozesse laufen auf unterschiedlichen Prozessoren ab (tatsächlich parallel)
- ein Prozessor wird "scheibchenweise" den Prozessen zugeordnet, sodass diese "überlappt" ablaufen (quasi-parallel)

Die im Zusammenhang mit der Parallelität von Prozessen auftretenden Probleme sind davon aber unabhängig.

Synchronisation konkurrierender Prozesse

Problem des wechselseitigen Ausschlusses

Das Problem des wechselseitigen Ausschlusses (*mutual exclusion*) wurde erstmals 1965 von Edsger W. Dijkstra formuliert.

Beispiel 1: Zwei zyklische Prozesse p_1 und p_2 benutzen von Zeit zu Zeit ein Magnetband. Es steht nur ein Gerät zur Verfügung, das nicht von mehr als einem Prozess gleichzeitig benutzt werden kann.

1. Lösungsversuch: Definition einer booleschen Variable frei

```
001 wiederhole
002 wiederhole bis frei;
003   frei := false;
004   benutze(magnetband)
005   frei := true;
... ...
FFF ständig\\
```

 p_1 :

```
p2:
001 wiederhole
002 wiederhole bis frei;
003    frei := false;
004    benutze(magnetband)
005    frei := true;
... ...
FFF ständig
```

Probleme:

- Wenn p_1 und p_2 parallel ablaufen, können sie auch gleichzeitig das Magnetband als frei erkennen. Das gleiche Problem kann auch bei quasi-parallel ablaufenden Prozessen auftreten, da jeder Prozess zwischen 002 und 003 unterbrochen werden kann.
- Durch die Warteschleife wird Prozessorzeit beansprucht (busy waiting).
- **2.** Lösungsversuch: Definition einer booleschen Variable planderReihe p_1 :

```
001 wiederhole
002
      wiederhole bis planderReihe;
003
      benutze(magnetband)
004
      planderReihe := false;
FFF ständig
p_2:
001 wiederhole
002
      wiederhole bis nicht planderReihe;
003
      benutze(magnetband)
004
      planderReihe := true;
. . . . . .
FFF ständig
```

Ein wechselseitiger Ausschluss ist zwar gewährleistet, allerdings müssen die Prozesse das Magnetband abwechselnd benutzen. Beide Prozesse müssen außerdem "am Leben" bleiben. Busy waiting tritt auch hier auf. 3. Lösungsversuch: Definition zweier boolesche Variablen plistdran und p2istdran Initialisierung:

```
p1istdran := false
p2istdran := false
p_1:
wiederhole
   p1istdran := true
   wiederhole bis nicht p2istdran
   benutze(magnetband)
   p1istdran := false
ständig
p_2:
wiederhole
   p2istdran := true
   wiederhole bis nicht p1istdran
   benutze(magnetband)
   p2istdran := false
ständig
```

Wechselseitiger Ausschluss ist zwar garantiert, es besteht aber die Gefahr der Verklemmung (deadlock).

Anforderungen an eine Lösung für das Problem des wechselseitigen Ausschlusses:

- 1. Das Betriebsmittel wird nach endlicher Zeit zugewiesen.
- 2. Ein Prozess gibt das Betriebsmittel nach endlicher Zeit wieder frei.
- 3. Ein Prozess, der wartet, soll keine Rechenzeit verbrauchen.
- 4. Eine Problemlösung soll von den Prozessen in eine gemeinsame Umgebung verlagert werden.

Das grundsätzliche Problem resultiert aus der "unkontrollierten" Benutzung gemeinsamer Betriebsmittel.

Weitere Beispiele für das Auftreten des Problems des wechselseitigen

Ausschlusses:

- 1. Veränderung von Datensätzen in einer von mehreren Prozessen gemeinsam benutzten Datei
- 2. gemeinsame Benutzung von Unterprogrammen mit lokalen Variablen für Zwischenergebnisse

Definition (kritischer Abschnitt):

Programmabschnitte, in denen sich zu einem Zeitpunkt nur jeweils ein Prozess befinden darf, heißen kritische Abschnitte (critical sections).

Lösung: P- und V-Operationen nach Edsger W. Dijkstra

 ${\tt P}$ und ${\tt V}$ sind zwei Operationen auf einer gemeinsamen Variablen, genannt Semaphorvariable. Jedem kritischen Abschnitt wird eine Semaphore zugeordnet.

Definition von P und V:

Beispiel für die Sicherung eines kritischen Abschnitts (Benutzung eines Magnetbandgeräts) ... durch eine Semaphore s:

```
P(s)
benutze(magnetband)
V(s)
```

Eigenschaften von P und V:

- sind selbst kritische Abschnitte
- müssen atomar sein (dürfen nicht selbst unterbrochen werden)
- Es handelt sich aber um **kurze** kritische Abschnitte, die im Systemkern realisiert werden, wo wechselseitiger Ausschluss einfach zu implementieren ist.
- Sie werden häufig mithilfe eines Spezialbefehls des Prozessors realisiert, wobei ein aktives Warten in Kauf genommen wird.
- Dazu wird eine Sperrvariable pv mit folgender Bedeutung eingeführt:

```
pv=1: P- und V-Operationen können ausgeführt werdenpv=0: P- und V-Operationen können nicht ausgeführt werden
```

Der Spezialbefehl teste_und_setze(pv) ... ist eine unteilbare Operation, die folgendermaßen arbeitet:

```
wiederhole solange pv = 0; (* tue nichts, busy waiting *) pv := 0
```

Mithilfe dieses Befehls werden nun zwei modifizierte Operationen P' und V' eingeführt, die dann zur Sicherung eines kritischen Abschnitts eingesetzt werden können.

```
P'(s)
    teste_und_setze(pv)
    P(s)
    pv:=1

V'(s)
    teste_und_setze(pv)
    V(s)
    pv:=1
```

Alternative Realisierung für Semaphore

- S ist ein Semaphoren-Objekt mit den Methoden wait() (mochte passieren) und signal() (verlassen).
- Ein Semaphoren-Objekt ist meist verbunden mit einer zugehorigen Prozess-Warteschlange W.

```
Prozess 1
S.wait();
i = leseZaehler();
i = i + 10;
schreibeZaehler( i );
S.signal();
Prozess 2
S.wait();
j = leseZaehler();
j = j - 5;
schreibeZaehler( j );
S.signal();
Realisierung eines binaren Semaphors
S.wait():
if ( TestAndSet(belegt) ) {
   Prozess in Warteschlange W einreihen;
   Prozess in Zustand ,,wartend" versetzen;
}
S.signal():
if ( W.empty() == false ) {
   Einen Prozess aus Warteschlange W losen;
   Prozess in Zustand "bereit" versetzen;
else { belegt = false; }
```

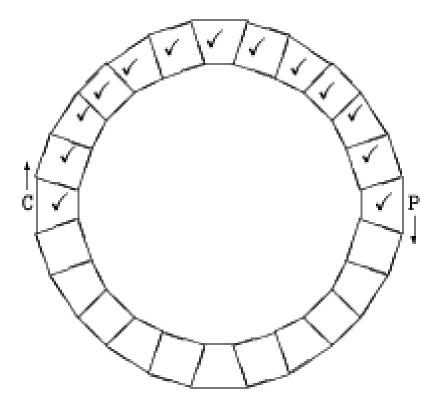
Realisierung eines Zahl-Semaphors

```
S.wait():
if ( FetchAndAdd( zaehler, -1 ) < 1) {
   Prozess in Warteschlange W einreihen;
   Prozess in Zustand ,,wartend" versetzen;
}

S.signal():
if ( FetchAndAdd( zaehler, 1 ) < 0 ) {
   Einen Prozess aus Warteschlange W losen;
   Gelosten Prozess in Zustand ,,bereit" versetzen;
}</pre>
```

Synchronisation kooperierender Prozesse

- Bisher wurden nur um gemeinsame Betriebsmittel konkurrierende Prozesse betrachtet, die sonst nichts miteinander zu tun hatten.
- Kooperation zwischen Prozessen kann z.B. heißen, dass Nachrichten zwischen einem Erzeuger und einem Verbraucher ausgetauscht werden (producer-consumer-problem).
- Nachrichtenaustausch soll gepuffert erfolgen, um Erzeuger und Verbraucher bezüglich ihrer Arbeitsgeschwindigkeit zu entkoppeln.
- Ringpuffer fester Größe kann nur eine feste Anzahl von Nachrichten speichern.
- Abbildung zeigt einen teilweise gefüllten Ringpuffer mit zwei Zeigern, c für den Verbraucher und p für den Erzeuger.



• Beide Prozesse bearbeiten den Puffer im Uhrzeigersinn. Durch die Prozesssynchonisation muss verhindert werden, dass sie sich gegenseitig "überholen".

Sychronisation von Erzeuger un Verbraucher durch Semaphore

• Die Prozesse benutzen jeweils eine Kommunikationsprozedur, SendeNachricht und EmpfangeNachricht, die dafür sorgen, dass derErzeuger wartet, wenn der Puffer voll ist, und der Verbraucher, wenn der Puffer leer ist.

Konsument

```
EmpfangeNachricht(puffer)
  while (true) {
    belegt.wait();
    mutex.wait();
    nachricht = holeAusPuffer();
    mutex.signal();
    frei.signal();
```

```
konsumiere(nachricht);
}

Produzent

SendeNachricht(puffer)
  while (true) {
    nachricht = erzeuge();
    frei.wait();
    mutex.wait();
    schreibeInPuffer(nachricht);
    mutex.signal();
    belegt.signal();
}

Initialisierung: mutex.zaehler = 1; frei.zaehler = max; belegt.zaehler = 0;
```

Nachteil dieser Lösung

- Die Verantwortung für die korrekte Synchronisation bzw. deren korrekte Programmierung liegt bei den Prozessen.
- Programmierfehler können dabei zu schwer reproduzierbarem Fehlverhalten (z.B. Verklemmungen) führen.

Weitere klassische Synchronisationsprobleme

Readers-Writers-Problem • Einige Prozesse/Threads wollen einen Datenbereich lesen, einige wollen ihn verandern.

- Gleichzeitiger Lesezugriff ist erlaubt.
- Schreibzugriffe mussen exklusiv erfolgen.

Dining-Philosophers-Problem • Funf Philosophen sitzen um einen runden Tisch, denken nach und essen Reis mit Stabchen.

• Zwischen den Tellern liegt jeweils ein Stabchen, zum Essen braucht man aber zwei.

Monitore

- Programmiersprachliches Konstrukt, funktional aquivalent zu Semaphoren
- Kritische Methoden und Daten werden in einer Klasse mit einem zugehorigen Semaphor kombiniert.
- Leichter zu handhaben, weniger fehleranfallig
- Unterstutzung der Synchronisation durch Bedingungsvariablen

Synchronisation durch Nachrichtenaustausch

- Die bisher betrachteten Synchronisationsprimitive sind nur einsetzbar, wenn die beteiligten Prozesse Zugriff auf einen gemeinsamen Speicherbereich (shared memory) haben, in dem sich z.B. die Semaphorvariablen befinden.
- Auf diese Art ist daher die Synchronisation in Verteilten Systemen, wo Prozesse auf unterschiedlichen Maschinen ablaufen können, nicht möglich.
- Hierfür werden neue Synchronisationsprimitive (Aufrufe des Systemkerns), die auf dem Austausch von Nachrichten (message passing) basieren, eingeführt:

```
send(destination,message)
receive(source,message)
```

- Mit send und receive können Prozesse synchronisiert werden, die auf Prozessoren ohne gemeinsamen Speicher ablaufen.
- Bei einem Aufruf von send wird der Prozess blockiert, wenn keine Nachricht übermittelt werden kann. Bei einem Aufruf von receive wird der Prozess blockiert, wenn keine Nachricht verfügbar ist.

Mögliche Schwierigkeiten bei der Nachrichtenübermittlung:

- Verlust einer Nachricht Abhilfe: jede gesendete Nachricht muss quittiert werden (*acknowledgement*), wiederholen der Nachricht beim Ausbleiben der Quittung
- Verlust der Quittung

- doppeltes Eintreffen einer Nachricht beim Empfänger Abhilfe: Numerieren der Nachrichten
- Eindeutige Benennung (Adressierung) von:
 - Prozessoren
 - Maschinen
 - domains
- Sicherheitsprobleme
- Effizienz, wenn Sender und Empfänger auf der gleichen Maschine laufen

Behandlung des *Producer-Consumer-Problems* mit *message passing*:

Annahmen:

end

- Nachrichten haben feste Länge.
- Gesendete, aber noch nicht empfangene Nachrichten werden vom Betriebssystem automatisch gepuffert.
- Maximal max Nachrichten können gepuffert werden.

```
Consumer:
    for i := 1 to max do send(producer,emptymessage);
    while true do begin
        receive(producer,message);
        extract_data(message);
        send(producer,emptymessage);
        process(data);
    end

Producer:
    while true do begin
        produce_data(data);
        receive(consumer,emptymessage);
        build_message(message,data);
        send(consumer,message);
```

Anmerkungen:

- Die Zahl der Nachrichten bleibt konstant.
- Für Pufferung ist ein fester Speicherbereich vorgesehen.
- Pufferung und Adressierung erfolgt durch sog. *mailboxes* bei Sender und Empfänger.
- in UNIX entsprechen sogenannte pipes den mailboxes.

Threads

Prozesse und Threads

Prozess • ein in Ausfuhrung befindliches Programm

- benotigt Ressourcen: Prozessor, Speicher (Programmcode, Daten, Stack), Dateien, E/A-Gerate
- bislang betrachtet: sequentiell arbeitende Prozesse (nur ein Ausfuhrungsstrang)

Thread • ein Ausfuhrungsstrang innerhalb eines Prozesses

- benotigt: Prozessor, eigenen Stack
- nutzt: Programmcode, Daten, Dateien, E/A-Gerate des Prozesses
- Mehrere Threads innerhalb eines Prozesses moglich

| Programmcode |
|---------------|
| Daten |
| Dateien |
| E/A-Geräte |
| Register |
| Stack |
| \mathcal{M} |

| Programmcode | | | |
|--------------|--|--|--|
| Daten | | | |
| Dateien | | | |
| E/A-Geräte | | | |
| Register | Register | Register | |
| Stack | Stack | Stack | |
| M | $\bigwedge \! \! \! \! \! \! \! \bigwedge$ | $\bigwedge \! \! \! \! \! \! \! \! \! \! \! \! \! \! \! \! \! \! \!$ | |

Ein Prozess mit einem Thread

Ein Prozess mit drei Threads

Beispiele fur Multithreading

- Anwendungen mit graphischer Benutzeroberflache, z.B. Textverarbeitung:
 - Texteingabe
 - Rechtschreibprufung
 - Ausdruck
- Serversoftware, z.B. Webserver, DB-Server:
 - Administration
 - Simultane Bearbeitung vieler Anfragen

Vorteile von Multithreading

- Kurzere Antwortzeiten Bei interaktiven Anwendungen kann auch auf Benutzereingaben reagiert werden, wahrend andere, langandauernde Aufgaben durchgefuhrt werden.
- **Gemeinsame Nutzung von Ressourcen** Auf gemeinsamen Speicher sowie gemeinsame Dateien und E/A-Gerate kann ohne weiteren Aufwand zugegriffen werden.
- Wirtschaftlichkeit Die Erzeugung eines neuen Threads und der Wechsel zwischen zwei Threads eines Prozesses verursacht erheblich weniger Auf- wand (im Vergleich zur Prozesserzeugung/zum Prozesswechsel).
- Nutzung von Multiprozessorarchitekturen Auch ein einziger multithreading Prozess kann gleichzeitig mehrere Prozessoren nutzen.

Anwender- und Kernel-Threads

Anwender-Threads Erzeugung, Scheduling und Verwaltung der Threads erfolgt uber spezielle Programm-Bibliotheken auf Ebene des Anwendungsprogramms. Fur den Kernel besteht das Programm aus einem einzigen, single-threaded Prozess.

Vorteil effizient (Kernel muss nicht eingreifen)

Nachteil Muss ein Thread warten, mussen es alle.

Kernel-Threads Erzeugung, Scheduling und Verwaltung der Threads werden durch das Betriebssystem unterstutzt.

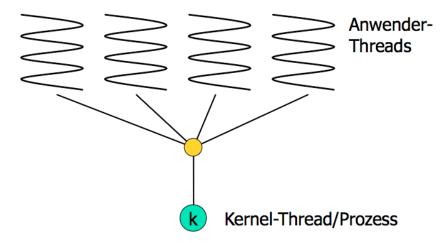
Vorteile Verteilung auf mehrere Prozessoren moglich; ein wartender Thread behindert die anderen Threads nicht.

Nachteil Etwas langsamer als Anwender-Threads.

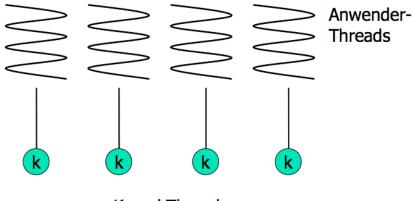
Multithreading-Modelle

- Many-to-One-Modell Mehrere Anwender-Threads werden auf einen Kernel-Thread abgebildet.
 - Beispiele: Green-Thread-Library bei Solaris 2, POSIX Pthread-Library, Betriebssysteme ohne Thread-Unterstutzung
- One-to-One-Modell Jeder Thread eines Anwendungsprogramms wird auf genau einen Kernel-Thread abgebildet
 - Beispiele: Windows NT, Windows 2000, OS/2
- Many-to-Many-Modell Die Threads der Anwendungsprogramme werden auf eine Anzahl von Kernel-Threads gemultiplext.
 - Beispiele: IRIX, HP-UX, Tru64 UNIX

Multithreading-Modelle: Many-to-One

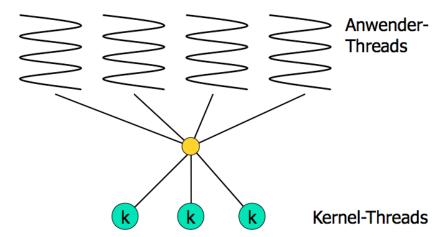


Multithreading-Modelle: One-to-One



Kernel-Threads

Multithreading-Modelle: Many-to-Many



Verklemmungen

Definition:

Eine Verklemmung (deadlock) bedeutet, dass zwei oder mehr Prozesse auf Ereignisse warten, die niemals eintreten werden ("Nach-Ihnen-Nach-Ihnen"-Schleifen, warten im "Kreis").

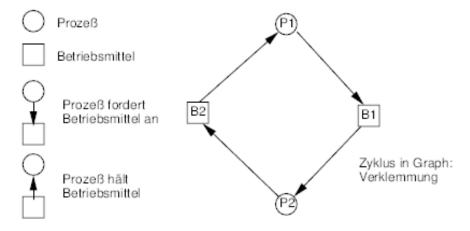
Beispiel: Verschachtelung von kritischen Abschnitten

Das Auftreten von Verklemmungen ist zeitabhängig. Ursachen sind im laufenden System schwer feststellbar und nicht ohne weiteres reproduzierbar.

Vier notwendige und hinreichende Bedingungen für das Auftreten von Verklemmungen:

- "Wechselseitiger Ausschluss"-Bedingung Ein Betriebsmittel, um das Prozesse konkurrieren, ist entweder frei oder genau einem Prozess zugewiesen.
- "Halte-und-warte"-Bedingung Prozesse mit bereits zugewiesenen Betriebsmitteln dürfen weitere Betriebsmittel anfordern (hold and wait).
- "Kein-Entzug"-Bedingung Prozesse geben Betriebsmittel nur von sich aus frei. Betriebsmittel können ihnen nicht zwangsweise entzogen werden.
- "Zirkuläres-Warten"-Bedingung Zwei oder mehr Prozessse warten wechselseitig auf Betriebsmittel, die von dem/den jeweils anderen gehalten werden.

Die vierte Bedingung wird, wie in Abbildung gezeigt, zur Modellierung von Verklemmungssituationen durch Graphen zum Zwecke der Verklemmungserkennung benutzt.



Vier Strategien mit dem Verklemmungsproblem umzugehen:

- Verklemmungen unmoglich machen
- Verklemmungen vermeiden
- Verklemmungen erkennen und beseitigen
- Verklemmungen ignorieren

Verklemmungen unmoglich machen

- Wechselseitigen Ausschluss verhindern (Bedingung 1 ist aufgehoben)
 - Z. B. Einrichten eines Druckerdaemonen
 - Probleme: nicht fur alle Betriebsmittel geeignet, nur Verlagerung auf andere Betriebsmittel
- Zusatzliche Betriebsmittelanforderungen verbieten (Bedingung 2 ist aufgehoben)
 - Z. B. Anforderung aller benotigten Betriebsmittel zu Prozessbeginn
 - Probleme: Unnotig lange Belegung der Betriebsmittel, schlechte Betriebsmittelauslastung
- Vorzeitige Betriebsmittelruckgabe erzwingbar machen (Bedingung 3 ist aufgehoben)
 - Z.B. Entzug nach einer bestimmten Zeit
 - Bei CPU selbstverständlich, bei E/A-Geräten meist nicht sinnvoll.
 - Probleme: muss ggf. auf Programmebene berucksichtigt werden, bereits geleistete Arbeitsleistung geht verloren
- Zirkularitat unterbinden (Bedingung 4 ist aufgehoben)
 - Z. B. lineare oder hirarchische Ordnung der Betriebsmittel, Anforderungen dann nur gemaß dieser Ordnung
 - Probleme: keine allgemein brauchbare Ordnung angebbar, deshalb oft schlechte Auslastung

Verklemmungsvermeidung

beruht auf der Grundidee, die Betriebsmittelanforderungen der Prozesse in eine "verklemmungsfreie" Reihenfolge zu bringen. Die Algorithmen (Vgl. Bankiersalgorithmus) hierfür sind teiweise sehr komplex und auch nur anwendbar, wenn der gesamte Betriebsmittelbedarf der Prozesse im Vorhinein bekannt ist, was in der Praxis häufig nicht der Fall ist. Nichtsdestotrotz hat sich um dieses Thema herum eine eigene mathematische Theorie entwickelt, auf die hier aber nicht eingegangen wird.

Bankiersalgorithmus

- Betrachtung der Betriebsmittelanforderungen als gleichzeitig auftretende Maximalforderungen
- Unterscheidung von
 - sicheren Zustanden (Verklemmung nicht moglich)
 - unsicheren Zustanden (Verklemmung nicht zwingend, bei ungunstiger Anforderungsreihen- folge aber moglich)
- Weitere Prozesse werden nur gestartet, wenn kein unsicherer Zustand entsteht.
- Auf die Darstellung weiterer Details wird hier verzichtet.

Probleme der Verklemmungsvermeidung

- I. A. Zahl der maximal benotigten Betriebsmittel unbekannt
- Standig wechselnde Zahl von Prozessen
- Zahl der verfugbaren Betriebsmittel ebenfalls veranderlich
- Algorithmus ist laufzeit- und speicherintensiv

Verklemmungen erkennen

- Analyse bei verdachtigen Symptomen:
 - viele Prozesse warten und der Prozessor ist unbeschaftigt
 - mindestens zwei Prozesse warten zu lange auf Betriebsmittel
- Bei Verdacht Start eines Erkennungsalgorithmus
 - B. Zyklen-Erkennung im Betriebsmittelgraphen

Verklemmungen beseitigen

- Prozesse abbrechen
- Prozesse zurucksetzen
- Betriebsmittel entziehen
- Probleme:
 - Prozess-/Betriebsmittelauswahl
 - Verlust bereits geleisteter Arbeit
 - Mogliche Inkonsistenzen
 - U. U. manueller Mehraufwand erforderlich

Verklemmungen ignorieren

- Erkennung von Verklemmungen aufwendig
- Beseitigung von Verklemmungen nicht unproblematisch
- Vermeidung bzw. Unmoglichmachen von Verklemmungen u. U. wenig effizient
- Verklemmungen sind in der Regel nicht das dringlichste Problem

verwendete Literatur

- [?]
- [?]
- [?]
- [?]